

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre

1

Fondamentaux de la fouille de données et prétraitement

Support de cours

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 1

Fondamentaux de la fouille de données et prétraitement

Table des matières

1	Introduction	2
2	Le processus KDD	2
2.1	Les cinq étapes	2
2.2	Documentation à produire	3
3	Représentation des individus et des variables	3
3.1	Typologie des variables	3
3.2	Créer de nouvelles colonnes	5
3.3	Quels tableaux peut-on analyser ?	5
3.4	Quels types de résultats cherche-t-on ?	5
4	Qualité des données et diagnostic	5
4.1	Valeurs manquantes	5
4.2	Doublons, incohérences et clés	6
4.3	Atypiques et bruit	6
5	Statistiques descriptives et exploration	6
5.1	Mesurer la similarité entre lignes	6
6	Imputation des valeurs manquantes	7
7	Mise à l'échelle et métriques de similarité	7
8	Discrétisation et encodage	8
8.1	Fusion de tables et réduction de volume	8
9	Protocole de séparation des échantillons	8
10	Transformations non linéaires et symétrie	9
11	Redondance, corrélation et sélection	9
12	Conformité, éthique et minimisation des données	9
13	Reproductibilité, sérialisation et monitoring	10
14	Synthèse et checklist	10
15	Questions de révision guidées	10

16 Fil conducteur d'un projet de prétraitement

10

1 Introduction

La **fouille de données** consiste à parcourir de grands tableaux pour trouver des **régularités utiles**, par exemple qui risque de ne pas rembourser un crédit, quels produits s'achètent ensemble, etc. Beaucoup de débutants veulent tout de suite « le meilleur algorithme ». En réalité, il faut d'abord cadrer le projet et **préparer** les données ; sans cela, les chiffres du modèle sont trompeurs. Le **prétraitement** (étape 2 du KDD) consiste à corriger, uniformiser et documenter le tableau *avant* toute fouille ou prédiction. C'est le cœur de ce chapitre. Nous le situons d'abord dans le **processus KDD** (section suivante), puis nous détaillons le diagnostic et le nettoyage. Les chapitres 2 à 4 s'appuient sur ce socle.

Objectifs pédagogiques

À la fin de ce chapitre, vous devriez savoir

- nommer les cinq étapes du KDD et expliquer le rôle du prétraitement ;
- reconnaître les types de variables (nombre, catégorie, note ordonnée) ;
- repérer manquants, doublons et valeurs aberrantes ;
- utiliser une chaîne scikit-learn (imputation, encodage, mise à l'échelle) ;
- séparer apprentissage et test sans **fuite d'information**.

2 Le processus KDD

Le sigle **KDD** (*Knowledge Discovery in Databases*, découverte de connaissances dans les bases de données) désigne une **façon de mener un projet**. Il s'agit de partir de données brutes ou de tables métier et arriver à une information utile, vérifiable et transmissible. Ce n'est ni le nom d'un logiciel unique, ni celui d'un seul algorithme.

On distingue le **KDD** (le parcours complet) et la **fouille de données** (*data mining*), qui correspond surtout à l'**étape 4** du processus. On y applique des méthodes (classification, regroupement, règles d'association, etc.) pour extraire des régularités d'un grand tableau. Les étapes qui précèdent préparent le terrain ; c'est pourquoi ce chapitre insiste sur la qualité des données avant toute fouille.

2.1 Les cinq étapes

Le KDD se décompose en cinq étapes enchaînées.

1. **Sélection.** Quelles données utiliser ? quelle période ? respect du cadre légal (données personnelles).
2. **Prétraitement.** Corriger les erreurs, uniformiser les formats, gérer les vides et les doublons.
3. **Transformation.** Créer de nouvelles colonnes utiles (ratio, moyenne sur 3 mois, etc.).
4. **Fouille.** Appliquer les méthodes de data mining (classification, regroupement, règles d'association, etc.).
5. **Interprétation.** Vérifier avec le métier, documenter, suivre l'évolution des données dans le temps.

En entreprise, les étapes 1 à 3 prennent souvent **la majeure partie du temps**. C'est normal. Des données propres évitent des décisions fausses et des corrections coûteuses. La fouille (étape 4) n'a de valeur que si les étapes amont sont maîtrisées.

2.2 Documentation à produire

Un **dictionnaire de données** décrit chaque colonne (nom, type, unité, source, sens métier, règles de calcul). On y joint la liste des transformations, des graphiques avant/après et la raison d'exclure certaines lignes, afin qu'un autre étudiant (ou vous, six mois plus tard) puisse refaire la même chaîne de calcul.

3 Représentation des individus et des variables

Chaque ligne du tableau (client, achat, patient) est décrite par plusieurs **variables explicatives** :

$$\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{ip})^\top \in \mathbb{R}^p \quad (1)$$

On obtient une matrice **X** avec n lignes et p colonnes. Chaque **ligne** (*individu, observation*) correspond par exemple à un client ou une transaction ; chaque **colonne** est une variable mesurée (âge, ville, montant). Les variables **explicatives** servent à expliquer ou prédire ; au chapitre 2, on ajoute une colonne **cible y** (étiquette à prédire (oui/non, classe, etc.).

3.1 Typologie des variables

Le **type** de variable guide le traitement. On distingue d'abord les variables **qualitatives** (modalités texte ou codes) et **quantitatives** (nombres). Une qualitative **nominale** n'a pas d'ordre naturel (ville, couleur) ; une **ordinaire** en a un (satisfaction de 1 à 5). Une quantitative **continue** accepte des décimales (montant) ; une **entière** compte des unités discrètes (nombre d'enfants). Mettre « rouge »=1 et « bleu »=2 comme des nombres ordonnés est en général une erreur. Il n'y a pas de « plus petit » ou « plus grand » entre des couleurs. Pour résumer une colonne, on utilise le **mode** (modalité la plus fréquente), la **médiane** (valeur centrale après tri) ou la **moyenne** (sensible aux valeurs extrêmes). Le tableau suivant donne des exemples et des traitements usuels.

Nature	Exemple	Traitements usuels
Catégorie (texte)	Ville, secteur	Compter, mode, colonnes 0/1 par catégorie
Note ordonnée	Satisfaction 1 à 5	Médiane ; garder l'ordre seulement si justifié
Nombre continu	Montant, durée	Moyenne, écart-type, graphiques, mise à l'échelle
Nombre entier	Nombre d'enfants	Comme un nombre continu si les valeurs sont petites




FIGURE 1 – Vue d’ensemble du processus de découverte de connaissances (KDD) : la fouille est une étape au sein d’une boucle itérative. (Source : Han, Kamber et Pei, *Data Mining: Concepts and Techniques*, 3e éd., Figure 1.4.)

3.2 Créer de nouvelles colonnes

Par exemple, endettement divisé par revenu ; total des achats sur les 90 derniers jours ; nombre de jours depuis le dernier achat. Il ne faut utiliser que des informations connues *au moment de la décision*. Ne pas inclure « ce qui s’est passé après », sinon le modèle triche.

3.3 Quels tableaux peut-on analyser ?

On rencontre plusieurs **sources** courantes pour cadrer un projet.

- **Base relationnelle.** Clients, produits, une ligne = un enregistrement structuré ;
- **Entrepôt de données.** Historique consolidé pour l’analyse (souvent des agrégats par période) ;
- **Données transactionnelles.** Paniers, logs, une ligne = un achat ou un événement ;
- **Autres.** Texte, graphes, flux (hors scope de ce polycopié).

En TD Master 2, on travaille surtout sur des fichiers **CSV** (tableau texte) chargés en **Data-Frame** pandas pour filtrer, compter et tracer des graphiques.

3.4 Quels types de résultats cherche-t-on ?

Avant de coder, il faut savoir **quelle question** on pose et quel **type de motif** on cherche. Une **description** résume un groupe (profil de clients). Une **classification** prédit une étiquette (oui/non, classe) ; une **régression** prédit un nombre (montant, durée). Un **clustering** forme des groupes sans étiquette connue. Les règles d’**association** relient des produits ou événements qui apparaissent ensemble. La recherche de **valeurs atypiques** vise la fraude ou les erreurs de saisie. Exemples de questions possibles.

- **Description.** Quel est le profil des clients fidèles ?
- **Classification / régression.** Ce client va-t-il défaut ? quel montant prévoir ? (chapitre 2)
- **Clustering.** Quels segments naturels dans la base ? (chapitre 3)
- **Association.** Quels produits s’achètent ensemble ? (chapitre 3)
- **Valeurs atypiques.** Quelles lignes sont suspectes ou incohérentes ?

Tous les motifs trouvés ne sont pas **intéressants**. On exige qu’ils soient *valides* (assez de support), *nouveaux* et *actionnables* pour le métier.

4 Qualité des données et diagnostic

4.1 Valeurs manquantes

Une **valeur manquante** (case vide, NA, null) signifie que l’information n’est pas disponible pour cette ligne et cette colonne ; ce n’est pas anodin (refus de répondre, oubli, non applicable). La plupart des algorithmes exigent une règle explicite. On peut **supprimer** la ligne, **remplacer** par une valeur typique (moyenne, médiane, mode) ou ajouter un indicateur « manquant oui/non ». Trois cas théoriques aident à réfléchir au biais. Il y a le manque **au hasard** (MCAR, comme une panne de saisie), le manque lié à d’autres colonnes visibles (MAR, ex. les jeunes omettent

plus souvent le revenu), le manque lié à la valeur cachée (MNAR, ex. les très hauts revenus non déclarés). En TD, on documente surtout *pourquoi* il manque des valeurs et on choisit une règle simple et traçable.

4.2 Doublons, incohérences et clés

Les doublons peuvent provenir de fusions de bases, de saisies multiples ou d'absence de clé stable. L'audit compare les effectifs avant/après `drop_duplicates` sur des clés métier (SIREN, IBAN masqué, identifiant client). Les incohérences (âge négatif, date de clôture antérieure à l'ouverture) exigent des règles métier explicites (correction, imputation ou exclusion tracée). Une **clé** identifie une ligne de façon unique (numéro client, numéro de dossier). Un **doublon** est la même entité répétée deux fois ou plus ; il fausse les comptages et les moyennes si on ne le corrige pas.

4.3 Atypiques et bruit

Une **valeur atypique** peut être une faute de frappe ou un cas rare mais réel (fraude). Une méthode simple consiste à utiliser l'écart interquartile (IQR) pour repérer les valeurs trop loin du quartile bas ou haut. Avant de supprimer, demander : « est-ce une erreur de saisie ? » et noter la décision. Le **bruit** désigne une erreur de mesure ou de saisie ; une valeur **atypique** est très éloignée de la majorité (souvent repérée avec l'IQR, écart interquartile).

5 Statistiques descriptives et exploration

Avant toute modélisation, une exploration systématique (**histogrammes**, **boxplots**, corrélations) permet de repérer variables constantes, quasi-dupliquées ou distributions asymétriques. Pour une variable quantitative X :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2)$$

La corrélation de Pearson mesure une relation *linéaire* entre X et Y :

$$r_{XY} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{(n-1) s_X s_Y} \quad (3)$$

Une corrélation nulle n'exclut pas une relation non linéaire ; l'exploration visuelle reste indispensable.

5.1 Mesurer la similarité entre lignes

Beaucoup d'algorithmes (k-NN, clustering) reposent sur une **distance**. Pour des nombres, la distance de **Minkowski** généralise la distance usuelle :

$$d(\mathbf{x}, \mathbf{y}) = \left(\sum_{j=1}^p |x_j - y_j|^h \right)^{1/h} \quad (4)$$

$h = 1$ correspond à la distance « Manhattan » (somme des écarts absolus); $h = 2$ donne la distance euclidienne. Pour des profils comparables (texte, panier), la **similarité cosinus** mesure l'angle entre deux vecteurs (peu sensible à la longueur totale). En pratique, une **distance** mesure l'écart entre deux lignes et une **similarité** (cosinus) indique si deux profils pointent dans la même direction; il faut choisir la mesure adaptée au type de colonnes et **standardiser** avant de calculer.

6 Imputation des valeurs manquantes

Remplacer une valeur manquante par une valeur choisie (moyenne, médiane, mode, ou prédiction à partir d'autres colonnes) pour pouvoir utiliser la ligne dans un modèle. Ce n'est pas « inventer la vérité ». C'est une convention qu'il faut documenter. **Imputation univariée**. Remplacer par la moyenne, la médiane (robuste aux outliers) ou la mode. Formellement, pour un manquant sur x_i :

$$\hat{x}_i = \bar{x} \quad \text{ou} \quad \hat{x}_i = \text{médiane}(X) \quad (5)$$

Imputation par groupe (médiane du revenu *par secteur*) réduit le biais lorsque MAR est plausible. **Imputation multivariée** (régression, KNNImputer, MICE) exploite les corrélations entre variables mais augmente la complexité et le temps de calcul.

Point d'attention

Calculer la médiane ou μ , σ sur l'ensemble des données *avant* la séparation train/test fait fuiter l'information du test vers l'entraînement. Toutes les statistiques de prétraitement doivent être apprises sur le **train** uniquement, puis appliquées au test via **transform**.

Utiliser, même indirectement, des informations du jeu de **test** (ou du futur) pour construire le modèle ou le prétraitement constitue une **fuite d'information**. Les scores paraissent alors excellents à l'évaluation mais s'effondrent en production. Exemple typique. Calculer la moyenne d'imputation sur tout le fichier avant de séparer train et test. Un **pipeline** enchaîne imputation, encodage, mise à l'échelle et modèle. La méthode **fit** apprend les paramètres sur le train (moyennes, catégories vues, etc.). La méthode **transform** applique les mêmes règles à d'autres jeux (validation, test, production) sans les réapprendre.

7 Mise à l'échelle et métriques de similarité

Les algorithmes basés sur les distances (k-NN, K-means, certains clustering) sont sensibles aux unités. Deux clients identiques sur l'âge mais différents sur un montant en euros peuvent paraître « très éloignés » si le montant domine la somme des carrés. **Normalisation min-max** sur $[0, 1]$:

$$x' = \frac{x - \min(x)}{\max(x) - \min(x)} \quad (6)$$

Standardisation (z-score), souvent préférée lorsque la distribution est unimodale :

$$z = \frac{x - \mu}{\sigma} \quad (7)$$

La distance euclidienne entre $\mathbf{x}$ et $\mathbf{y}$:

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{j=1}^p (x_j - y_j)^2} \quad (8)$$

Le **robust scaling** (médiane et IQR) limite l'influence des valeurs extrêmes. L'objectif de la **mise à l'échelle** est de rendre les unités comparables pour que le montant en euros n'écrase pas l'âge en années dans une distance ou un coefficient.

8 Discrétisation et encodage

La **discrétisation** transforme une variable continue en classes (quantiles pour des effectifs équilibrés, bornes métier pour l'interprétabilité). Voici des méthodes usuelles.

- **Discrétisation par bins.** Découper en intervalles de même largeur ou de même effectif ;
- **Histogramme.** Choisir les bornes où la densité change ;
- **Analyse en clusters ou arbre.** Laisser un algorithme suggérer des coupures (plus avancé).

L'**encodage one-hot** crée une colonne 0/1 par modalité de texte pour éviter un ordre numérique artificiel. Pour une variable à forte cardinalité (code postal), regrouper les modalités rares en « autres ». L'encodage *target* (remplacer une catégorie par la moyenne de y) est risqué. Il provoque une fuite vers la cible si mal fait.

8.1 Fusion de tables et réduction de volume

Intégration. Fusionner plusieurs tables (clients + commandes). Problèmes fréquents : même entité avec des clés différentes, colonnes redondantes, valeurs contradictoires. Analyser la **corrélation** et le test du χ^2 entre colonnes qualitatives aide à repérer la redondance. **Réduction.** Viser moins de colonnes ou de lignes pour aller plus vite. L'**ACP** (composantes principales, chapitre 3) crée quelques variables synthétiques qui résument l'essentiel de la variabilité. L'**échantillonnage** (sous-ensemble représentatif) est une autre voie lorsque n est très grand.

9 Protocole de séparation des échantillons

Pour estimer la généralisation, on sépare le jeu en trois parties

- un jeu **d'entraînement** pour ajuster le pipeline et le modèle ;
- un jeu **de validation** (ou validation croisée) pour les hyperparamètres ;
- un jeu **de test** *touché une seule fois* pour le rapport final.

En données temporelles (défaut de crédit, churn), la séparation doit respecter la chronologie. On entraîne sur le passé, tester sur le futur. Mélanger aléatoirement les mois mélange le futur et le passé et **sur-estime** les performances. On distingue le jeu **d'entraînement** (ajuster le modèle), de **validation** (comparer des réglages ou faire une **validation croisée** k -fold) et de **test** (performance finale, touché une seule fois).

Exemple commenté

Portefeuille clients. Sur 200 fiches, 8 % de revenus manquants, un doublon sur (nom, email), un montant aberrant (facteur 5 sur le max). La stratégie retenue est la suivante. imputation médiane par secteur, flag binaire « revenu imputé », standardisation de l'ancienneté et du revenu, conservation de l'outlier après validation fraude. Le pipeline `ColumnTransformer` est sérialisé avec le modèle pour la mise en production.

Cas pratique

Scoring bancaire, phase préparation. (1) Définir la cible « défaut à 12 mois » et la fenêtre d'observation des variables explicatives. (2) Produire un rapport d'audit (manquants, doublons, distribution des défauts). (3) Construire un pipeline : numériques (imputation médiane + `StandardScaler`), qualitatives (mode + `OneHotEncoder`). (4) `fit` sur le train de 2019–2021, `transform` sur 2022. Scripts associés : dossiers `exemples/` et `exercices/` du chapitre 1.

10 Transformations non linéaires et symétrie

De nombreuses variables économiques (revenu, montant de transaction, surface) présentent une **asymétrie à droite**. Quelques valeurs très grandes étirent la moyenne. Une transformation $\log(1+x)$ ou $\sqrt{x}$ rapproche la distribution d'une forme unimodale, stabilise la variance et améliore parfois les modèles linéaires ou la significativité des corrélations. La transformation doit être **monotone** pour préserver l'ordre des individus et documentée dans le dictionnaire de données. Lorsque des variables suivent des échelles multiplicatives (ratios entre produits), le log-transform des deux côtés peut lineariser une relation de type puissance. En revanche, les valeurs nulles ou négatives interdisent le logarithme direct. On utilise $\log(1+x)$ ou l'on corrige d'abord les incohérences.

11 Redondance, corrélation et sélection

Deux variables fortement corrélées apportent une information redondante. elles gonflent la variance des modèles linéaires et déforment les distances en clustering. Repérer $|r| > 0,9$ ou une variance inflation factor (VIF) élevée incite à **retirer** l'une des variables ou à les regrouper (ACP, somme, première composante). La sélection de variables (*feature selection*) peut être *filter* (test statistique avant modèle), *wrapper* (recherche guidée par la performance) ou *embedded* (pénalisation L1 dans la régression logistique). En Master 2, privilégier la simplicité. Moins de variables interprétables vaut mieux qu'un millefeuille instable.

12 Conformité, éthique et minimisation des données

Le RGPD impose une **finalité** claire, la minimisation des données personnelles et la traçabilité des traitements. Le prétraitement ne doit pas recomposer des données sensibles non autorisées (re-identification). Pseudonymiser les identifiants, limiter la rétention et séparer les rôles (data engineer vs modélisateur) font partie du pipeline autant que le `StandardScaler`. Les biais historiques

(sous-représentation de certaines populations dans les données passées) se **propagent** dans les imputations et les modèles. Documenter la composition de l'échantillon et tester la stabilité des statistiques par sous-groupe prépare les débats d'équité traités au chapitre 4.

13 Reproductibilité, sérialisation et monitoring

Un pipeline scikit-learn ajusté sur le train se sérialise (`joblib`) avec le modèle pour garantir que la production applique **exactement** les mêmes règles (seuils d'imputation, catégories vues à l'entraînement). Toute nouvelle modalité en production doit être gérée (`handle_unknown='ignore'` en one-hot). En production, monitorer la **dérive** (distribution des variables, taux de manquants, proportion de scores extrêmes. Un shift brutal (crise économique, changement de processus de saisie) invalide le prétraitement appris et exige une refonte ou un ré-entraînement planifié.

14 Synthèse et checklist

Étape	Question à se poser
Cadrage	Quelle décision ? Quelle période ? Quelles sources légales ?
Audit	Où sont les manquants, doublons, incohérences ?
Transformation	Les échelles sont-elles compatibles avec l'algorithme ?
Fuite	Toute statistique est-elle apprise sur le train seul ?
Documentation	Un tiers peut-il reproduire le flux ?

15 Questions de révision guidées

1. Citez les cinq étapes du KDD et la place du data mining.
2. Différenciez MCAR, MAR et MNAR sur un exemple de revenu manquant.
3. Pourquoi une imputation globale avant split train/test est une fuite ?
4. Comparez min-max et z-score ; dans quel cas préférer robust scaling ?
5. Quand l'encodage ordinal est-il acceptable pour une note 1 à 5 ?
6. Décrivez deux stratégies face à une variable nominale à 200 modalités.
7. Quels graphiques produisez-vous systématiquement lors de l'audit ?
8. Expliquez la différence entre outlier technique et signal métier rare.

16 Fil conducteur d'un projet de prétraitement

Cette annexe résume, sous forme narrative, le déroulement type d'un projet étudiant ou professionnel sur quatre semaines. **Semaine 1.** Cadrage avec le commanditaire (décision visée, contraintes légales), inventaire des fichiers sources, première requête SQL ou import Python, statistiques descriptives globales. **Semaine 2.** Rapport d'audit signé (manquants, doublons, schéma des clés), proposition de règles de nettoyage soumises à validation. **Semaine 3.** Implémentation du Pipeline, tests unitaires sur des micro-échantillons, comparaison avant/après sur une variable

métier (ex. taux de défaut par tranche de revenu imputé vs non imputé). **Semaine 4.** Sérialisation, note de version, passation au chapitre modélisation. Chaque livrable intermédiaire évite de découvrir en fin de projet que 40 % des identifiants clients ne sont pas joinables entre deux tables. Le prétraitement n'est pas une étape « technique basse ». C'est là que se joue la validité externe du modèle.