

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre 1

Fondamentaux de la fouille de données et prétraitement

Exercices

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 1 — Travaux dirigés

Thème : audit qualité, mise à l'échelle et pipeline sans fuite d'information.

Prérequis : exemple `exemples/01_audit_et_pretraitement.ipynb` ou `01_audit_et_pretraitement.py`, sections du cours sur KDD, manquants et pipelines.

Durée indicative : 3 h (dont 1 h 30 en Python).

0.1 Partie A — Comprendre et diagnostiquer

0.1.1 Exercice 1.1 — Rapport d'audit sur un fichier clients

Contexte. Une PME vous confie `clients.csv` avant un futur modèle de scoring. Vous devez produire un **rapport d'audit** (1 page) utilisable par un collègue.

Données. Exécutez `correction_ex01_audit.py` pour générer `clients.csv` (150 lignes simulées).

Travail demandé.

1. **Inventaire** : nombre de lignes, nombre de colonnes, type apparent de chaque colonne (nombre / texte).
2. **Manquants** : tableau des taux de valeurs manquantes (%). Interprétez en une phrase si le taux sur `montant_mensuel` est acceptable sans analyse métier supplémentaire.
3. **Doublons** : combien de lignes dupliquées sur (`nom`, `email`) ? Proposez une action (supprimer, fusionner, investiguer) et justifiez.
4. **Valeurs extrêmes** : sur `montant_mensuel` (hors manquants), calculez Q_1 , Q_3 , IQR et les bornes $Q_1 - 1,5 \times \text{IQR}$, $Q_3 + 1,5 \times \text{IQR}$. Combien de lignes sont flaguées ? **Ne supprimez pas** sans discussion.
5. **Graphique** : un boxplot ou histogramme de `montant_mensuel` commenté en deux phrases.

Livrables. Rapport + capture ou sortie console des statistiques clés.

0.1.2 Exercice 1.2 — Pourquoi standardiser avant une distance ?

Contexte. Un collègue veut du k-NN sur l'âge (années) et le chiffre d'affaires (k€) **sans** mise à l'échelle.

1. Donnez un **exemple numérique** avec deux clients A et B (âge et CA au choix, écart modéré sur l'âge, fort sur le CA). Calculez la distance euclidienne **brute**.
2. Expliquez en une phrase quelle variable domine le calcul et pourquoi c'est problématique pour le voisinage.
3. Sur un petit échantillon de référence (30 lignes simulées ou `clients.csv`), estimez moyenne et écart-type de chaque variable numérique, appliquez le **z-score** à A et B, puis recalculez la distance. Comparez.

Livrable. Tableau avant/après + 3 lignes de conclusion.

(Aide numérique possible via `correction_ex02_distance.py`.)

0.2 Partie B — Pipeline reproductible

0.2.1 Exercice 1.3 — Chaîne de prétraitement avec séparation train / test

Objectif. Construire un pipeline scikit-learn **correctement évalué** (sans fuite).

Données. `clients.csv` (ex. 1.1). Variables pour la modélisation : `montant_mensuel` (numérique), `ville` (catégorielle). Ignorez `nom` et `email` pour ce TD.

Étapes.

1. `train_test_split` 80 % / 20 %, `random_state=42`.
2. `ColumnTransformer` avec :
 - numériques : imputation **médiane** puis `StandardScaler` ;
 - ville : imputation **mode** puis `OneHotEncoder(handle_unknown="ignore")`.
1. ‘fit’ sur le train uniquement, transform sur train et test.
2. Indiquez la **forme** (`n`, `p`) des matrices train et test après transformation (`p` inclut les colonnes one-hot).

Questions écrites.

- Que se passerait-il si vous calculiez la médiane de `montant_mensuel` sur **tout** le fichier avant le split ?
- Pourquoi `handle_unknown="ignore"` est utile en production ?

Livrable. Script ou notebook commenté + réponses aux deux questions.

0.3 Partie C — Cas métier et révision

0.3.1 Exercice 1.4 — Revenus manquants en marketing

Énoncé. 15 % des revenus annuels sont manquants dans une base clients (5000 lignes). L’équipe veut segmenter puis cibler une campagne email.

Comparez **trois stratégies** :

1. Suppression des lignes incomplètes ;
2. Imputation par la **médiane globale** ;
3. Imputation par la **médiane par secteur d’activité**.

Pour chaque stratégie, rédigez :

- l’**effet sur la taille** de la base ;
- un **biais possible** (MCAR / MAR / MNAR, mélange de segments, etc.) ;
- une **recommandation prudente** (une phrase).

Livrable. Tableau synthèse (3 lignes × 3 colonnes) + paragraphe de recommandation finale (5-8 lignes).

0.3.2 Exercice 1.5 — Questions de cours (réponses courtes justifiées)

1. Citez les **cinq étapes du KDD** dans l'ordre. Où se place la fouille de données ?
2. Vrai ou faux : « Le data mining se fait avant le prétraitement. » Justifiez.
3. Pourquoi encoder une **ville** en one-hot plutôt qu'en entiers 1, 2, 3 ?
4. MCAR, MAR, MNAR : donnez **un exemple concret** pour chaque (une phrase).
5. Quelle est la différence entre **'fit'** et **'transform'** dans un pipeline scikit-learn ?
6. Citez **deux graphiques** que vous produisez systématiquement lors d'un audit exploratoire.

Livrable. Réponses numérotées (2–4 lignes chacune sauf question 1).