

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre 2

Classification supervisée et évaluation des modèles

Corrigés

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 2 — Corrigés

0.1 Exercice 2.1

Définitions.

- **FP** : non-spam classé spam $\rightarrow$ utilisateur rate un message important.
- **FN** : spam classé non-spam $\rightarrow$ nuisance, risque sécurité / phishing.

Calculs.

- Exactitude = $(180 + 750)/1000 = 0,93$
- Précision = $180/(180 + 20) = 0,90$
- Rappel = $180/(180 + 50) \approx 0,783$
- $F1 = 2 \times 0,90 \times 0,783 / (0,90 + 0,783) \approx 0,838$

Exactitude. Acceptable en apparence, mais masque **50 FN** coûteux ; une classe majoritaire « non-spam » gonfle le taux sans garantir la détection du spam.

Tuning. Privilégier le **rappel** (ou $F\beta$ avec $\beta > 1$, ou minimisation d'un coût pondéré), éventuellement abaisser le seuil de probabilité pour capturer plus de spam au prix de FP.

—

0.2 Exercice 2.2

Attendu (Iris binaire, scores indicatifs).

Interprétation. $k = 1$: voisin unique très sensible au bruit. k grand : vote majoritaire sur une zone large $\rightarrow$ **frontière trop simple**.

Script. `correction_ex22_knn.py`.

—

0.3 Exercice 2.3

Sur-apprentissage. Pour `max_depth` croissant, le score **train** tend vers 1 tandis que le score **CV** stagne puis **baisse** au-delà d'un optimum (souvent profondeur **3–5** sur Iris binaire).

Profondeur retenue. Celle qui **maximise le score CV** (pas le train).

Script. `correction_ex23_arbre.py`.

—

0.4 Exercice 2.4

```
Pipeline([
    ("scaler", StandardScaler()),
    ("clf", LogisticRegression(max_iter=5000)),
])
```

Stratification. Préserve la proportion de défauts dans train et test lorsque la classe est rare.

Coefficients. Signe = effet sur log-odds du défaut **à autres variables fixées** ; colinéarité $\rightarrow$ coefficients instables ou contra-intuitifs.

AUC. Ordre de grandeur attendu 0,75 sur le jeu simulé si le split est stratifié et le pipeline correct.

—

0.5 Exercice 2.5

$$H(Y) = -p \log_2 p - (1 - p) \log_2 (1 - p) \text{ (convention } 0 \log 0 = 0).$$

Dérivée : $\frac{dH}{dp} = -\log_2 p + \log_2 (1 - p)$; nulle en $p = 0,5$. Maximum car H est concave sur $(0, 1)$.