

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre

3

Clustering, règles d'association et analyse en composantes principales

Support de cours

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 3

Clustering, règles d'association et analyse en composantes principales

Table des matières

1	Introduction	2
1.1	Quelques définitions	2
2	Clustering : principes généraux	2
3	Algorithme K-means	3
3.1	Forces et limites	3
4	Choix du nombre de clusters	3
5	Clustering hiérarchique	4
6	Règles d'association	4
6.1	Algorithme Apriori	4
7	Analyse en composantes principales (ACP)	7
7.1	Évaluer un clustering	8
8	Étude retail : de la transaction à la campagne	8
9	Lien avec la décision marketing	8
10	Déroulé pas à pas de K-means (Lloyd)	9
11	Questions de révision guidées	9
12	Stabilité et validation des segments	10
13	Autres approches de clustering (panorama)	10
14	Workflow retail pour les règles d'association	10
15	ACP et clustering, complémentarité	10
16	Synthèse	10
17	Grille d'interprétation d'un segment	11

1 Introduction

Parfois on n'a **pas de colonne « réponse »** à prédire. On cherche seulement à **regrouper** des lignes similaires en **clusters** (groupes de clients ou de produits qui se ressemblent), à découvrir des **règles d'association** du type « si le produit A alors souvent B » dans les tickets de caisse, ou à **résumer** un tableau avec beaucoup de colonnes. C'est l'**apprentissage non supervisé**. Ce chapitre présente trois outils : K-means pour les groupes, Apriori pour les paniers, ACP pour visualiser en 2D. On réutilise le nettoyage et la mise à l'échelle du chapitre 1.

Objectifs pédagogiques

- expliquer à quoi sert un regroupement sans étiquette connue ;
- lancer K-means et choisir un nombre de groupes raisonnable ;
- calculer support, confiance et lift pour des règles ;
- lire un graphique ACP (part de variance expliquée) ;
- proposer une action concrète (promotion, placement produit) à partir d'un segment.

1.1 Quelques définitions

Apprentissage non supervisé. On dispose de variables $\mathbf{x}$ sans colonne cible y connue. L'objectif est d'explorer la structure du tableau (groupes, liens entre produits, axes de variation). *Exemple.* Segmenter des clients selon leurs achats sans savoir à l'avance combien de « types » existent ni comment les nommer.

Clustering (regroupement). Répartir les n lignes en K groupes de profils proches au sens d'une distance (souvent euclidienne sur variables standardisées). *Exemple.* Quatre segments RFM (récence, fréquence, montant) pour adapter les campagnes e-mail.

Centroïde. Point représentatif d'un groupe, en général la moyenne des coordonnées des membres. *Exemple.* En K-means, chaque client est affecté au centroïde le plus proche, puis les centroïdes sont recalculés jusqu'à stabilisation.

Transaction et itemset. Une **transaction** est un panier (ticket) ; un **item** est un produit. Un **itemset** est un ensemble de produits achetés ensemble dans une part suffisante des paniers. *Exemple.* {pain, lait} apparaît dans 40 % des tickets du matin.

Règle d'association. Notation $A \Rightarrow B$: lorsque A est dans le panier, B apparaît souvent aussi. On résume par **support**, **confiance** et **lift** (définis plus loin). *Exemple.* « Pâtes $\Rightarrow$ sauce tomate » pour un placement commun en rayon.

ACP. Analyse en composantes principales : nouvelles variables $Z_1, Z_2, \dots$ combinaisons linéaires des colonnes d'origine, ordonnées par variance expliquée. *Exemple.* Projeter 13 mesures chimiques sur un plan 2D pour visualiser des groupes de vins.

2 Clustering : principes généraux

On cherche à couper le tableau en K **groupes** tels que les lignes d'un même groupe se ressemblent et que les groupes diffèrent les uns des autres. Personne ne fournit la « bonne » partition : on combine des indices (coude, silhouette) et une **lecture métier** (profil, taille de segment, action

possible). Avant K-means, il faut mettre les variables numériques à la même échelle (chapitre 1). Sinon une colonne en euros domine une colonne en âge et fausse toutes les distances.

3 Algorithmes K-means

K-means minimise l'inertie intra-clusters :

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2 \quad (1)$$

où $\boldsymbol{\mu}_k$ est le **centroïde** (moyenne des points) du groupe C_k . L'algorithme de Lloyd alterne affectation au centroïde le plus proche et recalcul des centroïdes jusqu'à stabilisation ; la solution dépend de l'initialisation (plusieurs `n_init` en pratique).




FIGURE 1 – Itérations de l'algorithme k-means : affectation des points puis mise à jour des centroïdes. (Source : Han, Kamber et Pei, *Data Mining: Concepts and Techniques*, 3e éd., Figure 10.3.)

3.1 Forces et limites

Forces. K-means est rapide sur des tableaux de taille moyenne, facile à mettre en œuvre avec scikit-learn et lisible via les centroïdes (moyenne par variable dans chaque groupe). *Exemple.* Interpréter le cluster 2 comme « panier moyen élevé, achats récents » en lisant les centroïdes standardisés.

Limites. L'algorithme suppose des groupes **compacts et à peu près sphériques** ; deux vrais groupes en forme de croissant peuvent être mal séparés. Il est sensible aux valeurs extrêmes qui tirent les centroïdes. *Exemple.* Un client avec un montant aberrant peut attirer tout un centroïde.

Variantes utiles. **k-medoids** (PAM) remplace le centroïde par un **vrai individu** du groupe : plus robuste, plus lent. **DBSCAN** regroupe les zones denses sans fixer K à l'avance et marque les points isolés comme bruit. On la choisit quand la forme des groupes n'est pas sphérique ou que K est inconnu.

4 Choix du nombre de clusters

La **méthode du coude** examine $J(K)$. On cherche un « coude » où ajouter un cluster n'améliore plus suffisamment l'inertie. L'**indice de silhouette** moyen complète cette analyse. Pour

l'individu i :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (2)$$

$a(i)$ est la distance moyenne aux autres points *du même* cluster ; $b(i)$ la distance moyenne au cluster *le plus proche* (hors du sien). $s(i)$ proche de 1 indique une bonne adéquation ; proche de 0, une frontière floue ; négatif, une possible mauvaise affectation. *Exemple.* Si la silhouette moyenne chute fortement entre $K = 4$ et $K = 5$, le cinquième groupe est peut-être artificiel. Retenir K combine coude, silhouette **et** taille minimale de segment (éviter 0,5 % de la base, trop petit pour une campagne).

5 Clustering hiérarchique

L'approche **agglomérative** fusionne itérativement les deux clusters les plus proches jusqu'à une seule classe. La mesure de proximité entre clusters (**linkage**) change la forme des groupes.

- **Single.** Distance minimale entre points (effet chaîne) ;
- **Complete.** Distance maximale ;
- **Ward.** Minimisation de l'augmentation de variance intra (souvent performant sur données standardisées).

Le **dendrogramme** visualise les fusions ; une coupe horizontale fixe K . La complexité croît avec n ; pour de grands effectifs, échantillonner ou préférer K-means sur profils agrégés.

6 Règles d'association

Dans le retail ou l'e-commerce, chaque **transaction** (panier, ticket) est un ensemble d'**items** (produits). Une règle $A \Rightarrow B$ signifie que « la présence de A est associée à celle de B » ; on exige $A \cap B = \emptyset$.

$$\text{supp}(A \Rightarrow B) = P(A \cup B) \quad (3)$$

$$\text{conf}(A \Rightarrow B) = P(B | A) = \frac{\text{supp}(A \cup B)}{\text{supp}(A)} \quad (4)$$

$$\text{lift}(A \Rightarrow B) = \frac{\text{conf}(A \Rightarrow B)}{\text{supp}(B)} \quad (5)$$

Le **support** mesure la fréquence de la co-occurrence, la **confiance** vaut $P(B | A)$ et le **lift** compare à l'indépendance ($\text{lift} > 1$ indique une association positive). Une confiance élevée avec un support très faible peut décrire un artefact non généralisable.

6.1 Algorithme Apriori

Apriori fonctionne en **deux passes**.

1. Trouver les **itemsets fréquents** (ensembles de produits dont le support dépasse un seuil minimum).




Figure 10.6 Agglomerative and divisive hierarchical clustering on data objects $\{a, b, c, d, e\}$.




FIGURE 2 – Dendrogramme : hauteur de fusion et choix du nombre de groupes par une coupe horizontale. (Source : Han, Kamber et Pei, *Data Mining: Concepts and Techniques*, 3e éd., Figure 10.7.)

tions can help retailers develop marketing strategies by gaining insight into which items are frequently purchased together by customers. For instance, if customers are buying milk, how likely are they to also buy bread (and what kind of bread) on the same trip




FIGURE 3 – Schéma d’une analyse de panier (market basket) et d’une règle d’association. (Source : Han, Kamber et Pei, *Data Mining: Concepts and Techniques*, 3e éd., Figure 6.1.)

2. Dédire les **règles** $A \Rightarrow B$ et filtrer par confiance minimale.

Principe de **anti-monotonie**. Si un ensemble est rare, tous ses sur-ensembles le sont aussi ; on évite ainsi d'explorer des candidats inutiles. Un **itemset** est un ensemble de produits présents ensemble dans au moins $s\%$ des paniers ; une **règle forte** combine un itemset fréquent et une confiance élevée, mais le lift reste nécessaire pour juger l'utilité métier. Variante avancée, **FP-Growth** pour les très grands catalogues (moins de candidats explicites).

En TP, Apriori est appliqué sur une matrice binaire panier $\times$ produit (outil fourni au TD).

Exemple commenté

Sur huit paniers, si *pain* et *lait* apparaissent ensemble quatre fois et *pain* six fois, alors $\text{supp} = 0,5$ et $\text{conf} \approx 0,67$. Comparer au lift pour voir si *lait* est plus fréquent avec *pain* qu'en général.

7 Analyse en composantes principales (ACP)

L'ACP construit de nouvelles variables $\{Z_1, Z_2, \dots\}$, combinaisons linéaires orthogonales des variables centrées (réduites), classées par variance décroissante. Soit **S** la matrice de covariance (ou corrélation) :

$$z_{ij} = \mathbf{v}_j^\top \mathbf{x}_i \quad (6)$$

où $\mathbf{v}_j$ est le j -ième vecteur propre, associé à la valeur propre λ_j . La fraction de variance expliquée par les q premiers axes :

$$\frac{\sum_{j=1}^q \lambda_j}{\sum_{j=1}^p \lambda_j} \quad (7)$$

En pratique, représenter les individus sur (Z_1, Z_2) colore souvent les points par cluster K-means pour visualiser la séparation. L'ACP s'inscrit aussi dans la **réduction de dimension**. On conserve les q premiers axes qui portent l'essentiel de l'information (variance expliquée).




FIGURE 4 – Projection sur les deux premières composantes principales (variance maximale). (Source : Han, Kamber et Pei, *Data Mining: Concepts and Techniques*, 3e éd., Figure 3.5.)

7.1 Évaluer un clustering

Sans étiquette « vérité », on ne peut pas calculer une exactitude comme en classification. On enchaîne trois types de questions.

Tendance au clustering. Les données présentent-elles une structure de groupes ou sont-elles uniformes ? Des outils avancés (coefficient de Hopkins) existent ; en TD, un scatter plot ou une ACP 2D suffit souvent pour voir si des nuages apparaissent. *Exemple.* Points mélangés sans séparation visible : K-means produira des frontières arbitraires.

Nombre de clusters K . Méthode du coude, silhouette moyenne, parfois gap statistic. *Exemple.* Choisir $K = 3$ si le coude et la silhouette se stabilisent, et si trois profils métier distincts émergent.

Qualité et stabilité. Silhouette moyenne, accord entre deux exécutions (autre `random_state`), comparaison avec des labels externes si disponibles (indice de Rand ajusté). *Exemple.* Si le segment « dormants » contient à la fois des clients récents et des inactifs depuis deux ans, le clustering n'est pas exploitable tel quel.

La validation reste en fin de compte **qualitative** : profils cohérents, taille de segment, action marketing crédible.

8 Étude retail : de la transaction à la campagne

Considérons une chaîne de supermarchés. Les tickets sont agrégés en format panier $\times$ produit binaire. Après nettoyage (retours annulés, SKU rares fusionnés), Apriori avec support 0,01 sur six mois produit des centaines de règles. Le merchandising filtre $\text{lift} > 1,3$ et $\text{confiance} > 0,5$, puis retient « pâtes $\Rightarrow$ sauce tomate » pour un placement commun en rayon et « couches $\Rightarrow$ lingettes » pour un bundle promotionnel testé sur 20 magasins pilotes. Parallèlement, une K-means sur le score **RFM** (*récence, fréquence, montant*) standardisé crée quatre segments : « gros paniers réguliers », « occasionnels promo », « dormants », « nouveaux ». Chaque segment reçoit un canal (email, SMS, coupon caisse) calibré au chapitre 4 via des seuils de contact différents. Cette narration montre comment les trois blocs du chapitre (cluster, association, ACP) coexistent dans un même projet, sans qu'un seul algorithme suffise.

9 Lien avec la décision marketing

Un segment n'est utile que s'il suggère une **action différenciée** (offre, canal, pricing, fréquence de contact). Une règle d'association peut alimenter un cross-sell en caisse ou en recommandation en ligne. Documenter la taille du segment, le panier moyen, la récence et un test A/B avant déploiement national.

Cas pratique

Contexte. Le jeu **Wine** décrit 178 bouteilles avec 13 mesures chimiques (alcool, acides, etc.). Il n'y a pas de cible imposée pour le clustering : on cherche des **profils de vins** similaires et une **visualisation** en 2D.

Colonnes. Treize variables numériques continues ; une colonne **target** (cultivar 0, 1, 2) peut servir *après coup* pour vérifier si les groupes retrouvent des types connus (indice ARI),

sans l'utiliser pour construire les clusters.

Étapes suggérées (`notebook exemples/03_kmeans_pca_association.ipynb` ou script associé).

1. **Standardiser** les 13 variables (`StandardScaler`) : indispensable avant distances ou K-means.
2. Lancer **K-means** pour $K = 2, \dots, 8$; tracer l'inertie (coude) et la **silhouette moyenne**; retenir un K argumenté.
3. Faire une **ACP** sur les variables réduites; projeter les vins sur (Z_1, Z_2) et colorier par cluster K-means.
4. Optionnel : clustering hiérarchique **Ward** avec la même matrice; comparer les deux partitions (ARI si **target** disponible).
5. En TD paniers : sur le jeu simulé d'exercices, extraire **deux règles** $A \Rightarrow B$ avec support, confiance et lift commentés.

Livable attendu. Graphiques coude/silhouette + plan ACP commenté (que représente chaque groupe en une ou deux phrases). Scripts TD : `exercices/correction_ex31_kmeans.py`, `correction_ex32_hierarchical.py`.

10 Déroulé pas à pas de K-means (Lloyd)

Étape 0. Choisir K , initialiser K centroïdes (Forgy ou k-means++). **Étape 1.** Pour chaque $\mathbf{x}_i$, calculer les distances aux centroïdes et assigner i au cluster argmin. **Étape 2.** Recalculer chaque centroïde comme moyenne des points assignés; si un cluster est vide, réinitialiser son centroïde. **Étape 3.** Si les assignations ne changent plus (ou variation de J négligeable), stop; sinon retour à l'étape 1. Comprendre ce cycle aide à diagnostiquer les échecs : clusters vides (K trop grand), convergence lente (mauvaise initialisation), centroïdes tirés par outliers (envisager robust scaling ou DBSCAN). Tracer J à chaque itération sur un petit jeu pédagogique visualise la descente.

11 Questions de révision guidées

1. En quoi le clustering diffère-t-il fondamentalement de la classification supervisée?
2. Pourquoi Ward linkage est-il souvent préféré à single linkage sur données standardisées?
3. Interprétez un lift de 0,8 pour la règle $A \Rightarrow B$.
4. Que signifie une silhouette moyenne proche de 0?
5. Pourquoi applique-t-on l'ACP sur des variables réduites plutôt que brutes?
6. Donnez un exemple où une règle à haute confiance serait refusée par le métier.
7. Quelle est la différence entre inertie totale et inertie expliquée par K clusters?
8. Comment lieriez-vous un segment K-means à une campagne e-mail différenciée?

12 Stabilité et validation des segments

Un partitionnement K-means n'est pas unique. Un autre `random_state` ou un léger bruit peut modifier les frontières. Mesurer la **stabilité** (accord entre deux exécutions, indice de Rand ajusté entre bootstrap) évite de sur-interpréter un artefact. Croiser les segments avec des variables **externes** non utilisées au clustering (canal d'acquisition, région) valide leur sens : si le segment 2 concentre le e-commerce sans que le canal ait été dans **X**, le profil est crédible. Fixer une taille minimale de segment (ex. 5 % de la base) empêche de construire des micro-groupes non rentables pour les campagnes.

13 Autres approches de clustering (panorama)

DBSCAN regroupe des points denses et marque le bruit comme outlier. C'est utile lorsque K est inconnu et que la forme des clusters n'est pas sphérique. Les **mélanges gaussiens** (*Gaussian Mixture Models*) estiment des ellipses via EM ; ils généralisent K-means avec des covariances. Le choix de méthode dépend de n , de p , du temps CPU et du besoin d'interprétation (centroïdes vs probabilité d'appartenance).

14 Workflow retail pour les règles d'association

En pratique, on enchaîne ainsi. (1) filtrer les transactions trop courtes ; (2) fixer un support minimum pour éliminer le bruit ; (3) générer les règles ; (4) trier par lift puis confiance ; (5) valider avec un expert métier (compatibilité produit, marge) ; (6) tester en magasin ou en A/B sur recommandations. Une règle « bière $\Rightarrow$ couches » peut être statistiquement vraie le samedi soir et absurde comme action marketing le lundi matin sans contexte.

15 ACP et clustering, complémentarité

Réduire à q composantes avant K-means peut **débruiter** et accélérer le calcul lorsque p est grand, à condition que les premiers axes conservent suffisamment de variance (souvent 70 à 90 % cumulés selon le domaine). Représenter simultanément individus et variables (biplot) aide à nommer les axes mais demande de la prudence en lecture : corrélation n'est pas causalité.

16 Synthèse

Outil	Question typique
K-means	Quels profils compacts pour K fixé ?
Hiérarchique	Quelle structure à plusieurs échelles ?
Apriori	Quels produits acheter ensemble ?
ACP	Quels axes résument la variabilité ?

17 Grille d'interprétation d'un segment

Pour chaque cluster retenu, remplir une fiche : effectif et part (%), moyennes des variables clés vs global, modalité dominante des variables qualitatives, proposition de **persona** (nom métier), action marketing suggérée, risque (cannibalisation, faible marge). Pour une règle $A \Rightarrow B$, noter support, confiance, lift, marge des produits concernés, test A/B proposé (taille d'échantillon, durée). Sans cette discipline, le clustering devient un exercice graphique ; avec elle, il devient un input au comité produit. Les TP du dossier **exercices/** reprennent ces grilles en version simplifiée.