

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre 3

**Clustering, règles d'association et analyse en composantes
principales**

Corrigés

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 3 — Corrigés

0.1 Exercice 3.1

Scripts. `correction_ex31_kmeans.py`.

Coude / silhouette. Souvent $K = 3$ ressort (coude net vers 3-4 ; silhouette max ou proche du max à 3). Les 3 cultivars du jeu Wine permettent une **vérification a posteriori** avec la vraie étiquette (non utilisée au moment du choix de K dans un vrai projet non supervisé).

Profils. À rédiger à partir des centroïdes (ex. cluster avec alcool / flavanoids élevés vs cluster « plus léger »).

—

0.2 Exercice 3.2

ARI $\in [0, 1]$; 1 = partitions identiques à permutation près.

K-means (inertie, centroïdes) et Ward (fusion variance) **optimisent des critères différents** → partitions proches mais pas identiques ; ARI typique **0,7–0,95** selon K et échantillon.

Script. `correction_ex32_hierarchical.py`.

—

0.3 Exercice 3.3

Variance cumulée 3 PC. `pca.explained_variance_ratio_[:3].sum()` — souvent $> 0,65$ (valeur exacte dans le script).

PC1. Variables avec `abs(pca.components_[0])` maximal (souvent **proline, flavanoids, alcool** ou voisins) → interprétation « vins plus riches / plus colorés / plus alcoolisés » selon les signes.

—

0.4 Exercice 3.4

Comptages.

- $n = 8$ paniers ;
- paniers contenant **pain** : T1–T5, T7, T8 → **6** ;
- paniers contenant **pain et lait** : T1, T2, T5, T7 → **4**.

Support de la règle (itemset pain lait pour le support de co-occurrence, ou support de l’itemset antécédent selon convention cours) :

- Support $\text{supp}(A \Rightarrow B)$ souvent défini comme $P(A \cup B) = 4/8 = 0,5$ (co-occurrence pain et lait dans le panier).

Confiance : $P(\text{lait} \mid \text{pain}) = 4/6 \approx 0,667$.

Lift : $\text{conf}/P(\text{lait})$. Lait présent dans 5 paniers → $P(\text{lait}) = 5/8$. $\text{Lift} \approx 0,667/0,625 \approx 1,07$ → association **légèrement positive** (pas un lift « fort » type 1,5).

Métier. Règle plausible pour **proximité rayon** pain / lait ; lift modéré → ne pas sur-investir sans test A/B.

—

0.5 Exercice 3.5

Exemple de fiche.

Autres réponses acceptées si cohérentes et **actionnables**.