

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre 3

**Clustering, règles d'association et analyse en composantes
principales**

Exercices

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 3 — Travaux dirigés

Thème : clustering, règles d'association, ACP.

Prérequis : chapitre 1 (standardisation), exemple `exemples/03_kmeans_pca_association.ipynb` ou `.py`.

Durée indicative : 3 h 30.

0.1 Partie A — Clustering

0.1.1 Exercice 3.1 — Choix de K avec K-means

Jeu. `sklearn.datasets.load_wine` — **standardisez** les 13 variables (z-score sur tout le jeu pour ce TD exploratoire, ou train-fit si vous argumentez).

Travail.

1. Pour $K = 2, \dots, 8$, calculez **inertie** $J(K)$ et **silhouette moyenne**.
2. Tracez **inertie vs K** (coude) et **silhouette vs K** .
3. Proposez un K **justifié** par les deux critères (pas seulement « parce que 3 classes de raisin existent »).
4. Pour le K retenu, décrivez **en français** le profil de **deux clusters** (variables avec moyennes les plus hautes / basses).

Livrable. Deux graphiques + paragraphe de synthèse. Script : `correction_ex31_kmeans.py`.

0.1.2 Exercice 3.2 — Hiérarchique vs K-means

1. Appliquez un clustering **agglomératif** (`linkage='ward'`) sur Wine standardisé.
2. Tracez un **dendrogramme** sur **30 individus** maximum (échantillon reproductible `random_state=0`) pour lisibilité.
3. Coupez l'arbre pour obtenir **3 clusters** et comparez avec K-means ($K = 3$) via l'**ARI** (*Adjusted Rand Index*).
4. Expliquez pourquoi l'ARI peut être < 1 même si les deux méthodes « semblent raisonnables ».

Livrable. Dendrogramme + ARI + 4 lignes d'interprétation. Script : `correction_ex32_hierarchical.py`.

0.2 Partie B — ACP et association

0.2.1 Exercice 3.3 — Variance expliquée et lecture de PC1

Sur Wine standardisé :

1. Ajustez une **ACP** (PCA) sur les 13 variables.
2. Quelle **fraction cumulée** de variance est expliquée par les **3 premières** composantes ?

- Identifiez les **3 variables** avec les loadings les plus grands en **valeur absolue** sur PC1 et proposez une **étiquette métier** pour PC1 (ex. « intensité acide / alcool » — à argumenter).

Livrable. Chiffres + interprétation (6–10 lignes).

—

0.2.2 Exercice 3.4 — Support, confiance et lift (calcul à la main)

Transactions (8 paniers) :

Règle étudiée : $\{\text{pain}\} \Rightarrow \{\text{lait}\}$ ($A \cap B = \emptyset$ côté items uniques : antécédent pain, conséquent lait).

- Calculez **support** et **confiance** (détaillez numérateur / dénominateur).
- Calculez le **lift** et dites si l'association est **plus forte** que le hasard.
- Vérifiez avec `mlxtend.frequent_patterns` ou le code du notebook sur une matrice one-hot.

Livrable. Calculs manuscrits ou tableur + une ligne de conclusion métier (placement rayon).

—

0.3 Partie C — Mise en pratique marketing

0.3.1 Exercice 3.5 — Fiche segment

Contexte. Segmentation RFM + K-means → **4 clusters**. Le **cluster 2** : panier moyen **élevé**, fréquence d'achat **faible**, récence **moyenne**.

Remplissez une **fiche** :

Livrable. Fiche complète (tableau ci-dessus) — pas de code obligatoire.