

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre

4

Statistiques décisionnelles et aide à la décision

Support de cours

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 4

Statistiques décisionnelles et aide à la décision

Table des matières

1 Introduction	2
1.1 Quelques définitions	2
2 Prédiction et décision ne coïncident pas	2
3 Matrice de coûts et coût espéré	3
4 Seuil de décision (cas binaire)	3
5 Courbes CAP, lift et ciblage	3
6 Calibration des probabilités	4
7 Courbe CAP et gains cumulés (détail)	4
8 Rappel sur les tests d'hypothèses et les erreurs	4
9 Décision multicritère	4
10 Lien entre ROC, prévalence et décision	5
11 Questions de révision guidées	6
12 Exemple chiffré de seuil et de coût	6
13 Équité, discrimination et variables proxy	6
14 Scénarios et décision sous contrainte budgétaire	7
15 Gouvernance, KPI et documentation	7
16 Synthèse	7
17 Modèle de note de décision pour comité	7

1 Introduction

Un modèle produit un **score** (souvent une probabilité ou un indice de risque entre 0 et 1) ou une **classe**; la **décision**, elle, est l'action concrète prise par l'organisation (accorder le prêt, appeler le client, lancer la promo, fixer un budget). Ce chapitre montre comment passer du score à une **règle de décision** (seuil, coût des erreurs) et comment comparer des projets sur plusieurs critères.

Objectifs pédagogiques

- comprendre que l'AUC mesure le tri des scores, pas encore la bonne décision ;
- choisir un seuil τ quand une erreur coûte plus cher que l'autre ;
- lire un graphique de coût en fonction du seuil ;
- faire une note de synthèse simple (population, seuil, limites) ;
- utiliser une moyenne pondérée pour classer des projets.

1.1 Quelques définitions

Score. Nombre produit par le modèle (souvent une probabilité entre 0 et 1, ou un indice de risque). Il sert surtout à *classer* les individus du plus risqué au moins risqué. *Exemple.* $\hat{p} = 0,82$ de défaut pour un dossier crédit : le client est « haut dans la liste », pas encore refusé automatiquement.

Prédiction vs décision. La **prédiction** (classe ou score) est le résultat du calcul ; la **décision** est l'action réelle (accorder, refuser, appeler, envoyer une promo). *Exemple.* `predict()` avec seuil 0,5 dit « défaut » ; le comité crédit peut quand même accorder après examen manuel.

Seuil τ . Valeur telle que l'on déclenche l'action « positive » (alerte, refus, contact) si le score dépasse τ . *Exemple.* Avec $\tau = 0,7$, seuls les 15 % de scores les plus élevés sont flaggés ; avec $\tau = 0,3$, on flagge beaucoup plus de dossiers (plus de FN évités, plus de FP).

Matrice de coûts. Table qui associe un coût ou un gain à chaque couple (décision prise, réalité). *Exemple.* Refuser un bon client coûte 500 € de marge manquée ; accorder à un mauvais payeur coûte 2 000 € de perte.

Coût espéré. Moyenne des coûts sur la population pour une règle donnée (modèle + seuil). *Exemple.* Sur 10 000 tests, compter FP et FN, multiplier par les coûts unitaires, sommer : on compare plusieurs valeurs de τ .

AUC vs décision. L'AUC (chapitre 2) mesure la qualité du *classement* des scores ; elle ne dit pas quel seuil ni quelle action choisir. *Exemple.* Deux modèles de même AUC peuvent impliquer des coûts très différents selon τ et la prévalence du défaut.

2 Prédiction et décision ne coïncident pas

Un score élevé n'est pas encore « refuser le crédit ». On fixe un **seuil τ** (ou une règle du type « top 500 dossiers par mois »). Au-dessus du seuil, on déclenche l'alerte, le refus ou l'appel. En crédit, accorder à un mauvais payeur (**faux positif** au sens décisionnel) et refuser un bon client (**faux négatif**) n'ont pas le même coût financier ni le même impact client. Ces montants doivent

être estimés avec le métier **avant** de figer τ . Le chapitre 2 a appris à construire et comparer des scores ; ici on apprend à les **utiliser** dans l'organisation.

3 Matrice de coûts et coût espéré

Notons C_{ij} le coût de prendre la décision i lorsque l'état réel est j . Pour une règle $\delta(\mathbf{x})$:

$$\mathbb{E}[C] = \sum_{i,j} C_{ij} P(\text{décision } i, \text{ état } j) \quad (1)$$

Sur un échantillon de test, on estime la somme empirique à partir de la matrice de confusion obtenue pour un seuil τ donné. Tracer le **coût total en fonction de τ** révèle souvent un minimum net, bien loin de 0,5 par défaut. On peut associer un gain ou un coût à chaque cellule de la matrice de confusion, puis choisir le modèle *et* le seuil qui minimisent le coût total (ou maximisent le bénéfice net). La courbe ROC sert d'abord à comparer la **capacité de discrimination** ; la décision finale combine ROC, coûts et contraintes de volume (courbes lift et CAP, utiles en marketing). La **matrice de coûts** associe un coût ou un gain à chaque couple (décision, réalité) ; le **coût espéré** en est la moyenne sur la population, estimée sur le test pour chaque seuil τ .

4 Seuil de décision (cas binaire)

Dans un cadre simplifié à coûts unitaires c_{FP} et c_{FN} , un seuil bayésien indicatif est :

$$\tau^* = \frac{c_{FN}}{c_{FN} + c_{FP}} \quad (2)$$

Si le coût d'un faux négatif est plusieurs fois celui d'un faux positif, τ^* se rapproche de 1. On ne déclare « positif » (risque élevé) que pour les scores très grands, ce qui **réduit les FN** au prix de FP supplémentaires. Ajuster ensuite pour la **prévalence** du positif et pour des contraintes de capacité (nombre maximal de dossiers revus manuellement).

Point d'attention

La commande `predict()` utilise souvent $\tau = 0,5$ par défaut. En pratique, le seuil est un **choix métier** à documenter et à réviser si les données changent.

5 Courbes CAP, lift et ciblage

Pour prioriser les actions (relance, recouvrement, offre promotionnelle), on trie les individus par score décroissant. La **courbe CAP** (ou courbe de gains) compare la proportion de positifs captés à la proportion de la population contactée. Le **lift** au décile mesure l'enrichissement par rapport au hasard :

$$\text{lift}_d = \frac{\text{taux de positifs dans le décile } d}{\text{taux marginal de positifs}} \quad (3)$$

Un lift de 3 dans le premier décile signifie que ce décile concentre trois fois plus de positifs que la base moyenne. C'est utile pour dimensionner le budget contact lorsque l'on contacte les têtes

de liste triées par score.

6 Calibration des probabilités

L'AUC évalue le **rang** des scores, pas leur interprétation comme probabilité. Deux modèles peuvent avoir la même AUC mais des courbes de calibration différentes. On regroupe les prédictions en bins et on compare la fréquence observée de $y = 1$ à $\hat{p}$ moyen. Les méthodes **Platt scaling** et **régression isotonique**, entraînées sur un jeu de validation, corrigent un miscalibrage systématique. Un bon discriminateur (AUC) classe bien les individus ; une bonne **calibration** signifie que les $\hat{p}$ correspondent aux fréquences observées. Une bonne AUC n'implique pas une bonne calibration.

7 Courbe CAP et gains cumulés (détail)

On ordonne les n individus par score décroissant $\hat{p}_{(1)} \geq \hat{p}_{(2)} \geq \dots$. Pour un cut-off correspondant aux k premiers individus, la **courbe de gains cumulés** reporte la proportion de tous les positifs retrouvés dans ce top- k :

$$G(k) = \frac{\sum_{i=1}^k y_{(i)}}{\sum_{i=1}^n y_i}$$

si les $y_{(i)}$ sont alignés sur le tri par score. La courbe CAP compare $G(k)$ à la diagonale (tirage aléatoire) et à la perfection (tous les positifs d'abord). En campagne, choisir k tel que le budget contact fixe k/n et lire $G(k)$. Si $G(0,1n) = 0,4$, les 10 % têtes capturent 40 % des positifs. Cette lecture est plus proche du langage marketing que l'AUC seule, car elle parle de **volume contacté** et de **yield** attendu. Coupler CAP et coût espéré permet d'arbitrer entre élargir le ciblage (plus de TP, plus de FP) et rester sur un décile premium.

8 Rappel sur les tests d'hypothèses et les erreurs

Dans un test statistique, le niveau α borne l'erreur de type I (rejeter H_0 vraie). La puissance $1 - \beta$ quantifie la capacité à détecter un effet réel. Le parallèle avec la classification est pédagogique : abaisser τ augmente les positifs prédits, réduit les FN et augmente les FP, comme abaisser α rend le test plus conservateur. Les deux cadres exigent un **compromis explicite** avec le métier. L'erreur de type I (rejeter H_0 vraie) s'apparente au faux positif, l'erreur de type II au faux négatif.

9 Décision multicritère

Les projets réels combinent des critères conflictuels : ROI, risque, délai, impact carbone, charge IT. On normalise chaque critère g_j sur $[0, 1]$ (min-max ou cibles), puis on agrège :

$$U(a) = \sum_{j=1}^k w_j \tilde{g}_j(a), \quad \sum_j w_j = 1 \quad (4)$$

Les poids w_j traduisent la préférence du comité ; une **analyse de sensibilité** (faire varier

$w_j \pm 10\%$) teste la robustesse du classement. Les méthodes ELECTRE et PROMETHEE (surclassement, seuils de préférence) prolongent ce cadre lorsque la compensation linéaire est discutable.

Exemple commenté

Trois projets A, B, C notés sur ROI (à maximiser), risque et délai (à minimiser). Après normalisation, $U = 0,5 \widetilde{ROI} + 0,3(1 - \widetilde{risk}) + 0,2(1 - \widetilde{delay})$. Le projet B peut dominer grâce au ROI mais être pénalisé par le risque. Le comité doit expliciter si ce trade-off est acceptable.

Cas pratique

Contexte. On dispose d'un score de risque (probabilité de défaut ou de réponse à une campagne) sur un jeu **déséquilibré** simulé en TD. L'AUC du chapitre 2 indique que le modèle classe bien ; il reste à choisir **à partir de quel score** on agit et combien cela coûte en erreurs.

Données et modèle. Jeu simulé déséquilibré généré dans le notebook. Pipeline `StandardScaler + LogisticRegression` entraîné sur le train ; probabilités $\hat{p}$ sur le test.

Étapes suggérées (exemples/04_seuil_cout_roc_calibration.ipynb ou script TD).

1. Fixer des **coûts unitaires** avec le métier, par exemple $c_{FP} = 1$ et $c_{FN} = 8$ (un faux négatif coûte huit fois plus cher qu'un faux positif).
2. Pour chaque seuil τ entre 0,1 et 0,9 (pas de 0,05), construire la matrice de confusion et calculer le **coût total** sur le test.
3. Tracer le **coût en fonction de τ** et repérer le minimum ; comparer avec $\tau = 0,5$ par défaut de `predict()`.
4. Superposer la **courbe ROC** du même modèle (comparaison de discrimination, pas substitut au coût).
5. Optionnel : regrouper les $\hat{p}$ en **déciles** et vérifier si la part de positifs observée suit la probabilité moyenne (calibration grossière).

Livraison. Graphique coût vs τ , seuil retenu τ^* justifié en 5 à 8 lignes (coûts, prévalence, volume flaggé). Exercices complémentaires : multicritère (`correction_ex43_multicritere.py`).

10 Lien entre ROC, prévalence et décision

La prévalence $\pi = P(y = 1)$ influence le coût espéré même si l'AUC reste invariante par re-étiquetage monotone. Un score calibré sur une population à 2% de défauts produira des $\hat{p}$ bas en moyenne ; fixer $\tau = 0,5$ serait alors absurde. En pratique, on examine la distribution des $\hat{p}$ sur validation, les taux de défaut par décile, puis on choisit τ ou top- N en cohérence avec π et les coûts. La courbe ROC est utile pour **comparer des modèles** indépendamment de π ; la décision opérationnelle exige de **replacer** le modèle dans la prévalence $\pi = P(y = 1)$ et le budget réels.




FIGURE 1 – Comparer deux scores ou deux modèles avant de fixer un seuil opérationnel (AUC et forme de la courbe). (Source : Han, Kamber et Pei, *Data Mining: Concepts and Techniques*, 3e éd., Figure 8.20.)

11 Questions de révision guidées

1. Pourquoi `predict()` n'est-il pas suffisant pour déployer un score en crédit ?
2. Reformulez en mots la formule $\tau^* = c_{FN} / (c_{FN} + c_{FP})$ lorsque $c_{FN} \gg c_{FP}$.
3. Quelle différence entre bien calibré et bon discriminateur (AUC) ?
4. Comment un plafond de dossiers revus par mois modifie-t-il la règle de décision ?
5. Citez trois éléments obligatoires d'un dossier de modèle réglementaire.
6. En multicritère, pourquoi une analyse de sensibilité sur les poids w_j est-elle nécessaire ?
7. Reliez erreur de type I et faux positif dans un test vs dans un score.
8. Proposez un KPI de suivi mensuel autre que l'AUC.

12 Exemple chiffré de seuil et de coût

Supposons $c_{FP} = 2000$ € (perte moyenne sur un crédit accordé à tort) et $c_{FN} = 500$ € (marge manquée sur un bon client refusé). Sur 10 000 dossiers test, pour un τ donné, compter FP et FN et calculer $2000 \times FP + 500 \times FN$. Faire varier τ de 0,1 à 0,9 par pas de 0,05 produit une courbe en U ou en plateau. Le minimum indique le seuil **empirique** à confirmer avec le métier. Ce calcul simple évite les débats purement intuitifs.

13 Équité, discrimination et variables proxy

Un score peut être statistiquement performant tout en reproduisant des inégalités historiques si des variables proxy du genre, de l'origine ou du code postal entrent dans $\mathbf{X}$. Analyser les taux

d'acceptation par sous-groupe, documenter les variables exclues et tester des scénarios de suppression de features sensibles font partie de la **responsabilité** du modélisateur. La réglementation (scoring crédit, assurance) évolue ; le dossier de modèle doit tracer les choix.

14 Scénarios et décision sous contrainte budgétaire

Parfois le nombre de dossiers examinés manuellement est plafonné ($N_{\max}$ par mois). On retient alors les $N_{\max}$ scores les plus élevés plutôt qu'un τ fixe. C'est la règle de **budget de review**. Le lift et la CAP servent à estimer combien de positifs sont captés dans ce top- N . Combiner coût espéré et contrainte de capacité est typique des centres d'appels fraude.

15 Gouvernance, KPI et documentation

Un dossier de modèle destiné à un auditeur ou un régulateur contient une définition de la population et période, label y , liste blanche des variables, protocole train/test, métrique principale, courbe ROC, seuil retenu et coûts, date de dernière recalibration, procédure de monitoring de dérive. Sans ce socle, le meilleur algorithme reste une « boîte noire » non déployable.

16 Synthèse

Concept	Usage
AUC	Comparer la capacité de rang des scores
Seuil τ	Traduire score en action
Coût espéré	Optimiser la règle sous contraintes réelles
Lift / CAP	Prioriser les contacts
Multicritère	Arbitrer des projets ou scénarios
Calibration	Interpréter $\hat{p}$ comme fréquence

17 Modèle de note de décision pour comité

Une note d'une à deux pages accompagne le déploiement d'un score. Chaque rubrique répond à une question simple du comité.

Contexte. Quelle population (clients actifs, nouvelles demandes) ? quelle période d'historique ? quel taux de défaut ou de réponse observé ? *Exemple.* « Prêts personnels 2022–2024, taux de défaut 12 %. »

Modèle. Quelle famille (logistique, arbre) ? quelles variables principales ? quelle AUC sur test hors période si possible ? *Exemple.* « Logistique, 8 variables, AUC = 0,78 sur test 2024. »

Règle de décision. Seuil τ retenu, coûts unitaires FP/FN, coût espéré estimé, alternative top- N si budget de revue limité. *Exemple.* « $\tau = 0,35$, coût moyen 4,2 €/dossier vs 6,1 € avec $\tau = 0,5$. »

Capacité opérationnelle. Combien de dossiers flaggés par mois ? qui traite les recours ? *Exemple.* « 800 dossiers/mois en file manuelle, délai 48 h. »

Suivi. KPI mensuels (volumes, taux de défaut par décile de score), **PSI** (écart de distribution des scores entre deux périodes), date de revue. *Exemple.* « $\text{PSI} > 0,25$ déclenche un audit data. »

Risques. Variable externe critique, biais résiduel, stress macro (+2 points de taux). **Dérive.** Les nouvelles données ne ressemblent plus à celles d'entraînement ; il faut ré-entraîner ou ajuster τ .

Ce gabarit privilégie la clarté sur *qui décide quoi* lorsque le score dépasse τ , plutôt que le détail des algorithmes.