

Université de Ngaoundéré

Master 2

Data Mining, Fouille de données
et Statistiques décisionnelles

Chapitre 4

Statistiques décisionnelles et aide à la décision

Exercices

Dispensé par

Pr Ndam Njoya Arouna

Chapitre 4 — Travaux dirigés

Thème : seuils, coûts, calibration et aide multicritère à la décision.

Prérequis : chapitre 2 (probabilités, ROC), exemple `exemples/04_seuil_cout_roc_calibration.ipynb` ou `.py`.

Durée indicative : 2 h 30.

—

0.1 Partie A — Coûts et seuils

0.1.1 Exercice 4.1 — Coût total d'une politique de décision

Contexte crédit. Classe positive = **défaut**. Coûts unitaires : $c_{FP} = 2$ (accorder à tort), $c_{FN} = 10$ (refuser un bon client).

Sur un échantillon test, un modèle donne **FP** = 15 et **FN** = 8 (les autres cellules de la matrice ne changent pas le coût total).

1. Calculez le **coût total** $C = c_{FP} \times FP + c_{FN} \times FN$.
2. Si l'on **abaisse** le seuil de probabilité (plus de dossiers refusés / flaggés), que deviennent qualitativement **FN** et **FP** ? Le coût total **doit-il** toujours baisser ?
3. Rédigez **deux phrases** pour expliquer le résultat à un responsable non technique.

Livrable. Calcul + réponses 2 et 3.

—

0.1.2 Exercice 4.2 — Seuil optimal simplifié

On retient $c_{FP} = 1$, $c_{FN} = 4$. La règle de seuil (cas binaire, coûts proportionnels) donne $\tau^* = \frac{c_{FP}}{c_{FP} + c_{FN}} = 0,8$.

1. Expliquez **en français** pourquoi on exige une probabilité de défaut **élevée** avant de classer « positif ».
2. Que se passerait-il avec $\tau = 0,5$ si les FN coûtent **4 fois** plus cher que les FP ?
3. Le seuil τ^* remplace-t-il une **validation sur données réelles** ? Répondez en 3 lignes.

Livrable. Réponses courtes numérotées.

—

0.2 Partie B — Multicritère et Python

0.2.1 Exercice 4.3 — Classement de projets

Trois projets **A**, **B**, **C** :

Critères : ROI à **maximiser**, risque et délai à **minimiser**. Poids : $w_{ROI} = 0,5$, $w_{risque} = 0,3$,

$w_{délai} = 0,2$.

Méthode.

1. Normalisez chaque critère sur $[0, 1]$ (**min-max** sur les 3 projets). Pour risque et délai, utilisez $1 - \tilde{x}$ pour que « plus haut = mieux ».

2. Calculez $U = 0,5 \widetilde{\text{ROI}} + 0,3 (1 - \widetilde{\text{risque}}) + 0,2 (1 - \widetilde{\text{délai}})$.
3. Classez A, B, C. Commentez le **compromis** (un projet peut gagner sur ROI et perdre sur le risque).

Livable. Tableau intermédiaire + classement. Vérification :
`correction_ex43_multicritere.py`.

—

0.2.2 Exercice 4.4 — Courbe coût vs seuil

Reprenez le notebook `exemples/04_seuil_cout_roc_calibration.ipynb` (jeu simulé du chapitre).

1. Tracez **coût total** en fonction du **seuil** τ (au moins 15 points entre 0,1 et 0,9).
2. Marquez le seuil τ^* qui minimise le coût (ligne verticale ou annotation).
3. Comparez τ^* au seuil **0,5** par défaut : gain de coût relatif en %.

Livable. Graphique + 3 lignes de commentaire.

—

0.3 Partie C — Gouvernance

0.3.1 Exercice 4.5 — Note pour comité de crédit

Un modèle de scoring doit être **explicable** pour un auditeur.

1. Comparez une **régression logistique** (coefficients) et un **arbre de profondeur 3** (règles si/alors) sur **trois critères** : lisibilité métier, risque de sur-apprentissage, stabilité dans le temps.
2. Proposez **une recommandation** (une méthode principale + une méthode de contrôle) en 5–8 lignes.

Livable. Tableau 3×3 + paragraphe de recommandation (pas de code).